Guide de déploiement — Pipeline ETL Sun Séjour

Mouhamed Nourou Dine Cissé

Juin 2026

Vue d'ensemble

Ce dossier contient le pipeline ETL du projet **Datamart Sun Séjour**. Il permet de charger automatiquement les fichiers de transferts et d'excursions dans la base de données SQL Server existante.

Principe de fonctionnement :

1. L'utilisateur dépose un nouveau fichier dans le bon dossier
2. Il double-clique sur `lancer_pipeline.bat`
3. Le pipeline s'exécute et charge les données dans le Datamart

Le pipeline tourne dans un **container Docker Python isolé** — il n'installe rien sur le PC, n'interfère avec aucun logiciel existant, et se connecte au SQL Server déjà en place.

Prérequis (installation unique)

1. Docker Desktop

Docker est le seul logiciel à installer. Il crée un environnement Python isolé sur votre PC.

Téléchargement : `https://www.docker.com/products/docker-desktop/`

Choisir la version **Windows (AMD64)**.

Après installation, lancer **Docker Desktop** depuis le menu Démarrer et attendre que l'icône en bas à droite soit verte (« Docker Desktop is running »).

> **Note :** Docker Desktop doit rester ouvert en arrière-plan lors de chaque utilisation du pipeline.

2. SQL Server — autoriser les connexions TCP

Le pipeline se connecte à votre SQL Server existant. Il faut vérifier que les connexions TCP sont activées (opération unique) :

1. Ouvrir **SQL Server Configuration Manager**
2. Aller dans *SQL Server Network Configuration -> Protocols for MSSQLSERVER*
3. Vérifier que **TCP/IP** est en statut *Enabled*
4. Si ce n'était pas le cas : clic droit -> Enable, puis redémarrer le service SQL Server

---

Configuration initiale

Ouvrir et modifier le fichier `.env`

Le fichier `.env` contient les informations de connexion à votre SQL Server. Il doit être configuré **une seule fois** avant le premier lancement.

Ouvrir le fichier `.env` avec le Bloc-notes (clic droit -> Ouvrir avec -> Bloc-notes) :

```
DB_SERVER=host.docker.internal
DB_USER=sa
DB_PASSWORD=MyStrongPass123
DB_NAME=Datamart
DB_PORT=1433
```

Seul `DB_PASSWORD` doit être modifié : remplacer `MyStrongPass123` par le mot de passe de votre compte `sa` SQL Server.

Les autres valeurs sont correctes et ne doivent pas être changées.

> **Important :** Ne pas modifier `DB_SERVER=host.docker.internal`. Cette valeur est nécessaire pour que Docker puisse atteindre votre SQL Server.

Utilisation quotidienne

Étape 1 — Déposer les fichiers source

Type de données	Dossier destination	Format attendu
Données de transfert	`transfert_data\`	`.xlsx`
Données d'excursion	`excursion_data\`	`.xls`

Vous pouvez déposer **plusieurs fichiers à la fois**. Le pipeline les traitera tous.

Les fichiers déjà traités lors d'un run précédent ne seront **pas dupliqués** dans la base — le pipeline détecte automatiquement les nouvelles lignes.

Étape 2 — Lancer le pipeline

Double-cliquer sur `lancer_pipeline.bat`

Une fenêtre noire s'ouvre et affiche la progression en temps réel :

```
[1/2] Preparation de l'environnement Python...
      (premiere fois : peut prendre 2-3 minutes)

[2/2] Execution du pipeline ETL...
      Cela peut prendre quelques minutes.

  Connexion a SQL Server en cours... Connexion OK.

  Lancement du pipeline ETL...
    Transform... OK
    Validate... OK
    Load... OK
    CA Script... OK
```

```
============================================================
  SUCCES : Donnees chargees dans le Datamart !
  Les logs sont dans le dossier : logs\
============================================================
```

Appuyer sur une touche pour fermer la fenêtre.

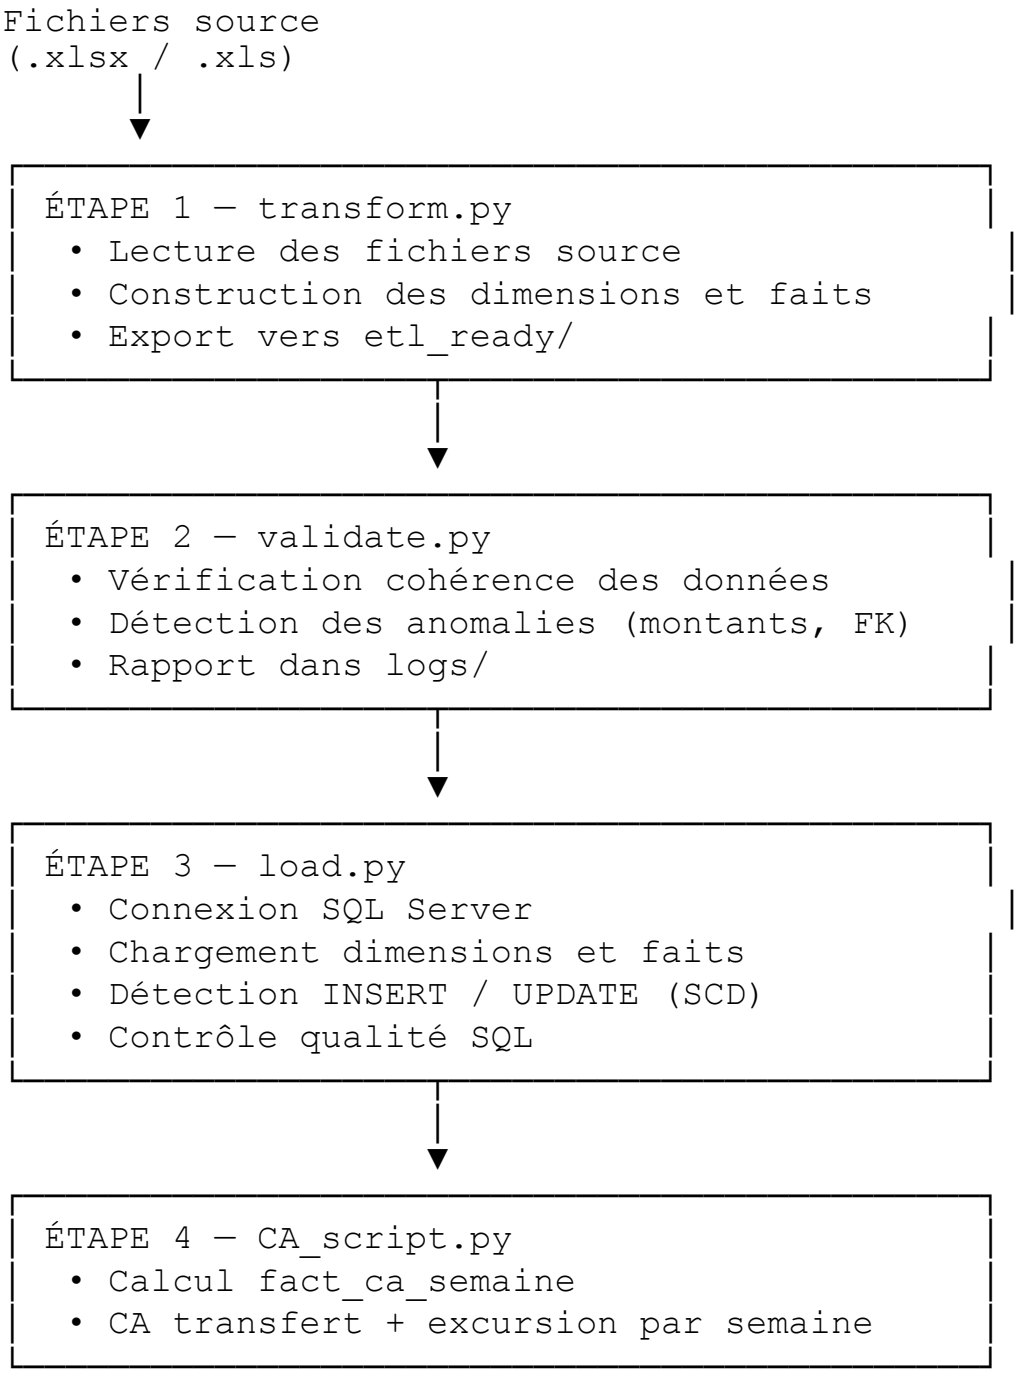
Durées indicatives

Situation	Durée estimée
Première exécution (téléchargement image Python)	3 à 5 minutes
Exécutions suivantes	1 à 3 minutes selon volume

Structure du dossier

```
Rendu Projet\
│
├── lancer_pipeline.bat          ← SCRIPT PRINCIPAL (double-clic ici)
├── .env                         ← configuration mot de passe SQL
│
├── transfert_data\              ← DEPOSER LES FICHIERS .xlsx ICI
├── excursion_data\              ← DEPOSER LES FICHIERS .xls ICI
├── logs\                        ← rapports générés automatiquement
├── etl_ready\                   ← fichiers intermédiaires (ne pas modifier)
│
├── pipeline.py                  ← orchestrateur du pipeline
├── transform.py                 ← étape 1 : extraction et transformation
├── validate.py                  ← étape 2 : validation des données
├── load.py                      ← étape 3 : chargement dans SQL Server
├── CA_script.py                 ← étape 4 : calcul du chiffre d'affaires
├── config.py                    ← lecture de la configuration .env
│
├── Dockerfile                   ← définition de l'environnement Python
├── docker-compose.yml           ← orchestration Docker
├── entrypoint.sh                ← script de démarrage du container
└── requirements.txt             ← dépendances Python
```

Fonctionnement du pipeline (4 étapes)



Si une étape échoue, le pipeline s'arrête et affiche le message d'erreur. Les étapes suivantes ne sont pas exécutées.

Résolution des problèmes courants

« Docker n'est pas démarré »

Ouvrir **Docker Desktop** depuis le menu Démarrer. Attendre que l'icône en bas à droite devienne verte, puis relancer `lancer_pipeline.bat`.

« ERREUR de connexion à SQL Server »

Causes possibles :

1. **Mauvais mot de passe** -> vérifier `DB_PASSWORD` dans le fichier `.env`
2. **TCP/IP désactivé** -> activer dans SQL Server Configuration Manager (voir section Prérequis)
3. **Pare-feu Windows** -> autoriser le port 1433 pour les connexions locales

Pour tester la connexion manuellement, ouvrir SQL Server Management Studio et tester avec les mêmes identifiants que dans `.env`.

« Le pipeline a échoué »

Ouvrir le dossier `logs\` et consulter le fichier `.log` le plus récent. Les erreurs y sont détaillées avec la ligne exacte du problème.

La première exécution est très lente

C'est normal : Docker télécharge l'image Python (~150 Mo) et installe les dépendances. Les exécutions suivantes seront rapides car tout est mis en cache.

Tables créées dans le Datamart

Le pipeline crée et alimente les tables suivantes :

Dimensions transfert

- `dim_date_transfert` — dates et heures de transfert
- `dim_client` — clients (commun transfert + excursion)
- `dim_hotel` — hôtels (commun)
- `dim_flight` — vols
- `dim_currency` — devises et taux
- `dim_status_transfert` — statuts de transfert
- `dim_airport` — aéroports et centres

Dimensions excursion

- `dim_date_excursion` — dates de réservation, arrivée, excursion
- `dim_excursion` — catalogue des excursions
- `dim_vendeur` — vendeurs
- `dim_status_excursion` — statuts d'excursion

Tables de faits

- `fact_transfert` — réservations de transfert
- `fact_excursion` — tickets d'excursion
- `fact_joint` — jointure transfert × excursion (même client, hôtel, date)
- `fact_ca_semaine` — chiffre d'affaires agrégé par semaine

Tables techniques ETL

- `etl_run_log` — historique des exécutions (inserts, updates, durée)
- `etl_checkpoint` — reprise sur erreur

Pipeline ETL — Datamart Sun Séjour — Mouhamed Nourou Dine Cissé — ENSIIE 2026