RAPPORT TECHNIQUE

Projet Datamart & ETL
Sun Séjour

Auteur	Mouhamed Nourou Dine Cisse
Client	Sun Séjour
Version	4.0 — Production
Date	Mars 2026
Statut	**Livraison finale — Diese, Junior Entreprise de l'ENSIIE**

1. Contexte et Objectifs

Ce projet a été réalisé par Diese, la Junior Entreprise de l'ENSIIE (École Nationale Supérieure d'Informatique pour l'Industrie et l'Entreprise), dans le cadre d'une mission de conseil et développement pour Sun Séjour. Sun Séjour est un logiciel de gestion hébergé sur serveur web/cloud pour la gestion des réservations de transferts aéroportuaires et d'excursions touristiques. Les données étaient stockées dans le système opérationnel sans être centralisées ni historisées.

L'objectif du projet est de concevoir et déployer une architecture datamart complète permettant :

- La centralisation des données de transferts et d'excursions dans une base décisionnelle unique
- L'automatisation mensuelle de la mise à jour des données via un pipeline ETL incrémental
- La mise à disposition de tables de chiffre d'affaires analytiques pour le reporting
- La préparation à la connexion d'outils BI (Power BI / Tableau)

2. Stack Technique

Domaine	Outil / Version	Rôle
Langage ETL	Python 3.13.2	Pipeline extraction et chargement
Data Processing	pandas 2.3.3 / numpy 2.3.3	Transformation et modélisation
Connecteur DB	pymssql 2.3.9	Connexion SQL Server
Base de données	SQL Server (Docker)	Stockage du datamart
Planification	cron (macOS)	Exécution automatique mensuelle
Analytics SQL	T-SQL / SSMS	Calcul des tables CA

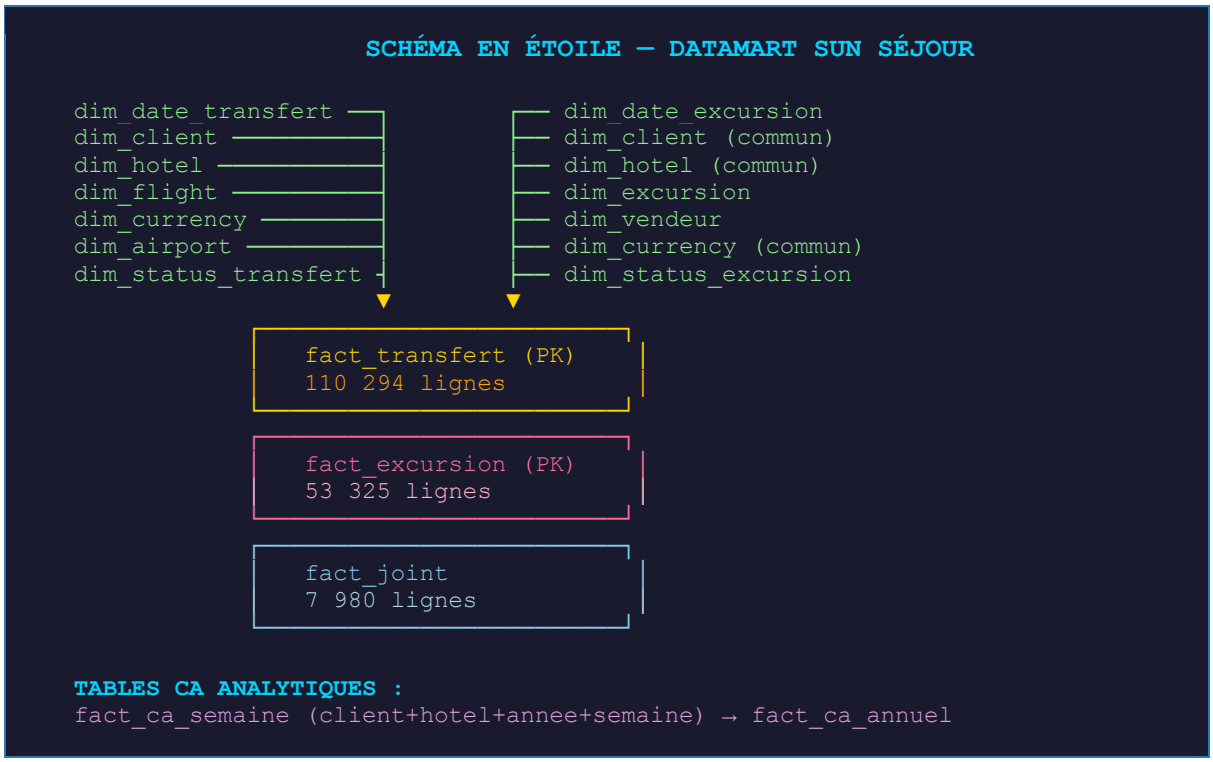
Note : Le cahier des charges prévoyait Talend Open Studio comme outil ETL. Dans le cadre de la mission Diese, le pipeline a été développé en Python pur avec pymssql, offrant des performances équivalentes et une meilleure maintenabilité, sans nécessiter de licence Talend côté client.

3. Modélisation — Schéma en Étoile

3.1 Vue d'ensemble

Le datamart repose sur un schéma en étoile avec deux tables de faits indépendantes (transferts et excursions) reliées à onze tables de dimensions. Les tables métier sont 100% propres — aucune colonne technique n'est visible.

3.2 Schéma logique



3.3 Relations clés étrangères

Contrainte	Table source	Colonne	Table référencée
FK_ft_date	fact_transfert	date_id	dim_date_transfert
FK_ft_client	fact_transfert	client_id	dim_client
FK_ft_hotel	fact_transfert	hotel_id	dim_hotel
FK_ft_currency	fact_transfert	currency_id	dim_currency
FK_ft_flight	fact_transfert	flight_id	dim_flight
FK_ft_airport	fact_transfert	airport_id	dim_airport
FK_ft_status	fact_transfert	status_id	dim_status_transfert
FK_fe_date	fact_excursion	date_id	dim_date_excursion
FK_fe_client	fact_excursion	client_id	dim_client
FK_fe_hotel	fact_excursion	hotel_id	dim_hotel

Contrainte	Table source	Colonne	Table référencée
FK_fe_currency	fact_excursion	currency_id	dim_currency
FK_fe_excursion	fact_excursion	excursion_id	dim_excursion
FK_fe_vendeur	fact_excursion	vendeur_id	dim_vendeur
FK_fe_status	fact_excursion	status_id	dim_status_excursion

4. Dictionnaire de Données

Légende :

PK	Clé primaire
FK	Clé étrangère

4.1 Tables de Faits

fact_transfert — 110 294 lignes | PK : Num_Reservation

Colonne	Type	Nullable	Clé	Description
Num_Reservation	**BIGINT**	**Non**	**PK**	**Identifiant unique de la réservation de transfert**
Num_Dossier	NVARCHAR	Oui		Numéro de dossier commercial
Mission	BIGINT	Oui		Code de mission opérationnelle
Pax	NVARCHAR	Oui		Nombre de passagers
A	NVARCHAR	Oui		Indicateur adulte
E	NVARCHAR	Oui		Indicateur enfant
B	NVARCHAR	Oui		Indicateur bébé
Montant	FLOAT	Oui		Chiffre d'affaires du transfert (devise de référence)
Montant Local	NVARCHAR	Oui		CA en devise locale
client_id	BIGINT	Oui	FK	Référence vers dim_client
hotel_id	BIGINT	Oui	FK	Référence vers dim_hotel
currency_id	BIGINT	Oui	FK	Référence vers dim_currency
date_id	BIGINT	Oui	FK	Référence vers dim_date_transfert
airport_id	BIGINT	Oui	FK	Référence vers dim_airport
flight_id	BIGINT	Oui	FK	Référence vers dim_flight
status_id	BIGINT	Oui	FK	Référence vers dim_status_transfert

fact_excursion — 53 325 lignes | PK : Num_Ticket

Colonne	Type	Nullable	Clé	Description
Num_Ticket	**BIGINT**	**Non**	**PK**	**Identifiant unique du ticket excursion**
Num_Reservation	NVARCHAR	Oui		Référence réservation source
Code_Facture	NVARCHAR	Oui		Code de facturation
Position	NVARCHAR	Oui		Position dans le bon de commande
Nbr Adt	NVARCHAR	Oui		Nombre d'adultes
Nbr Enf	NVARCHAR	Oui		Nombre d'enfants
Nbr bb	NVARCHAR	Oui		Nombre de bébés

Colonne	Type	Nullable	Clé	Description
Nbr Adt Grt	NVARCHAR	Oui		Adultes gratuits
Nbr Enf Grt	NVARCHAR	Oui		Enfants gratuits
Nbr bb Grt	NVARCHAR	Oui		Bébés gratuits
Montant	FLOAT	Oui		Chiffre d'affaires de l'excursion
client_id	BIGINT	Oui	FK	Référence vers dim_client
hotel_id	BIGINT	Oui	FK	Référence vers dim_hotel
currency_id	BIGINT	Oui	FK	Référence vers dim_currency
date_id	BIGINT	Oui	FK	Référence vers dim_date_excursion
excursion_id	BIGINT	Oui	FK	Référence vers dim_excursion
vendeur_id	BIGINT	Oui	FK	Référence vers dim_vendeur
status_id	BIGINT	Oui	FK	Référence vers dim_status_excursion

fact_joint — 7 980 lignes | PK : (transfert_reservation, excursion_reservation)

Colonne	Type	Nullable	Clé	Description
transfert_reservation	**NVARCHAR**	**Non**	**PK**	**Num_Reservation du transfert correspondant**
excursion_reservation	**NVARCHAR**	**Non**	**PK**	**Num_Reservation de l'excursion correspondante**
client_id	BIGINT	Oui		Identifiant client commun
hotel_id	BIGINT	Oui		Identifiant hôtel commun
Date_Transfert	NVARCHAR	Oui		Date du transfert (format AAAA M JJ)
Date_Arrivee	NVARCHAR	Oui		Date d'arrivée excursion (format JJ/MM/AAAA)

4.2 Tables de Dimensions

dim_client — 140 lignes

Colonne	Type	Nullable	Clé	Description
Client	NVARCHAR(255)	Oui		Nom du client ou de l'agence
client_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_hotel — 245 lignes

Colonne	Type	Nullable	Clé	Description
Hotel	NVARCHAR(255)	Oui		Nom de l'hôtel
hotel_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_date_transfert — 24 319 lignes

Colonne	Type	Nullable	Clé	Description
Date	NVARCHAR(255)	Oui		Date du transfert (format AAAA M JJ)
Heure	NVARCHAR(255)	Oui		Heure du transfert
date_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_date_excursion — 11 022 lignes

Colonne	Type	Nullable	Clé	Description
Date_Reservation	NVARCHAR(255)	Oui		Date de réservation de l'excursion
Date_Arrivee	NVARCHAR(255)	Oui		Date d'arrivée du client à l'hôtel
Date_Excursion	NVARCHAR(255)	Oui		Date effective de l'excursion (JJ/MM/AAAA)
date_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_flight — 1 208 lignes

Colonne	Type	Nullable	Clé	Description
Num_Vol	NVARCHAR(255)	Oui		Numéro de vol associé au transfert
flight_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_airport — 13 lignes

Colonne	Type	Nullable	Clé	Description
Airport	NVARCHAR(255)	Oui		Code ou nom de l'aéroport
Centre	NVARCHAR(255)	Oui		Centre de gestion associé
airport_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_currency — 7 lignes

Colonne	Type	Nullable	Clé	Description
Monnaie	NVARCHAR(255)	Oui		Code devise (ex: EUR, TND)
Taux	FLOAT	Oui		Taux de change vers devise de référence
currency_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_excursion — 83 lignes

Colonne	Type	Nullable	Clé	Description
Excursion	NVARCHAR(255)	Oui		Libellé de l'excursion
excursion_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_vendeur — 121 lignes

Colonne	Type	Nullable	Clé	Description
Vendeur	NVARCHAR(255)	Oui		Nom du vendeur ou de l'agent de vente
vendeur_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_status_transfert — 8 lignes

Colonne	Type	Nullable	Clé	Description
Position	NVARCHAR(255)	Oui		Position opérationnelle du transfert
Evénement	NVARCHAR(255)	Oui		Evénement associé (arrivée, départ, etc.)
status_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

dim_status_excursion — 10 lignes

Colonne	Type	Nullable	Clé	Description
Situation	NVARCHAR(255)	Oui		Situation commerciale (confirmé, annulé, etc.)

Colonne	Type	Nullable	Clé	Description
Etat_Excursion	NVARCHAR(255)	Oui		Etat opérationnel de l'excursion
status_id	**BIGINT**	**Non**	**PK**	**Identifiant unique auto-incrémental**

4.3 Tables analytiques CA

fact_ca_semaine — Table centrale CA

Colonne	Type	Nullable	Clé	Description
client_id	**BIGINT**	**Non**	**PK**	**Identifiant client**
hotel_id	**BIGINT**	**Non**	**PK**	**Identifiant hôtel**
annee	**INT**	**Non**	**PK**	**Année de la date d'arrivée**
semaine	**INT**	**Non**	**PK**	**Numéro de semaine de la date d'arrivée**
ca_transfert	DECIMAL(10,2)	Non		CA total des transferts pour ce client/hôtel/semaine
ca_excursion	DECIMAL(10,2)	Non		CA total des excursions pour ce client/hôtel/semaine
ca_total	DECIMAL(10,2)	Non		ca_transfert + ca_excursion

fact_ca_annuel — Sous-total annuel

Colonne	Type	Nullable	Clé	Description
client_id	**BIGINT**	**Non**	**PK**	**Identifiant client**
hotel_id	**BIGINT**	**Non**	**PK**	**Identifiant hôtel**
annee	**INT**	**Non**	**PK**	**Année**
ca_transfert_annuel	DECIMAL(10,2)	Non		CA transferts sur l'année
ca_excursion_annuel	DECIMAL(10,2)	Non		CA excursions sur l'année
ca_total_annuel	DECIMAL(10,2)	Non		CA global annuel

5. Pipeline ETL

5.1 Phase 1 & 2 — Extraction et Transformation (transform.py)

- Lecture des fichiers .xlsx (transferts) via pandas.read_excel()
- Lecture des fichiers .xls (excursions) via pandas.read_html()
- Construction des dimensions communes (dim_client, dim_hotel, dim_currency) par fusion des deux sources
- Génération des IDs auto-incrémentaux pour chaque dimension
- Mapping des IDs dans les tables de faits par jointures pandas
- Dédoublonnage sur Num_Reservation et Num_Ticket
- Export final vers etl_ready/dim_final/ et etl_ready/fact_final/

5.2 Phase 3 — Chargement SQL Server (load.py)

Synchronisation intelligente par hash MD5

- Chaque ligne est hachée via MD5 sur ses colonnes non-PK
- Les hashs sont stockés dans etl_control — table technique invisible au datamart métier
- Comparaison hash CSV vs hash base pour détecter INSERT / UPDATE / inchangé
- Les dimensions ne subissent pas de DELETE physique (intégrité référentielle préservée)
- Les faits supportent INSERT + UPDATE + DELETE

Optimisations de performance

Problème résolu	Solution implémentée
Timeout 60s sur 24k+ lignes	save_control via table temp ##etl_ctrl_save + UPDATE/INSERT en 2 statements
UPDATE lent sur 100k+ lignes	bulk_update_via_temp : table temp ##upd_{table} + JOIN en 1 aller-retour SQL
PK duplicate au premier run	Bootstrap automatique d'etl_control depuis la base existante
Colonnes techniques visibles	Hash stocké dans etl_control séparée, jamais dans les tables métier
Chargement trop lent	Chunks de 2 000 lignes par batch

6. Contrôle Qualité

6.1 Résultats du dernier run

Vérification	Résultat	Statut
Orphelins FK — fact_transfert (7 checks)	0	✅ OK
Orphelins FK — fact_excursion (6 checks)	0	✅ OK
NULL fact_transfert.Montant	0	✅ OK
NULL fact_transfert.client_id	0	✅ OK
NULL fact_excursion.Montant	0	✅ OK
NULL fact_excursion.vendeur_id	0	✅ OK
Montants <= 0 — fact_transfert	304 / 110 294 (0.28%)	⚠️ WARNING
Montants <= 0 — fact_excursion	737 / 53 325 (1.38%)	⚠️ WARNING
Doublons Num_Reservation	0	✅ OK
Doublons Num_Ticket	0	✅ OK

Note : Les montants <= 0 correspondent à des avoirs et remboursements présents dans les données source. Ils sont tracés dans des fichiers CSV d'anomalies mais conservés dans le datamart pour exhaustivité.

7. Livrables et État d'Avancement

7.1 Fichiers livrés

Fichier	Type	Description
transform.py	Python	Extraction et transformation des sources
load.py	Python	Chargement SQL Server v4.0 avec hash MD5
CA.py	Python	Calcul des tables CA — re-runnable
config.py	Python	Configuration centralisée (connexion DB)
validate.py	Python	Validation avant/après run + 33 checks cohérence
logs/etl_YYYYMMDD.log	Log	Journal horodaté de chaque run

Calcul des tables CA — re-runnable

7.2 État d'avancement par phase

Phase	Intitulé	Statut
Phase 1	Connexion & Exploration de la base Sun Séjour	✅ Terminée
Phase 2	Modélisation du datamart (schéma en étoile)	✅ Terminée
Phase 3	Flux ETL — extraction, transformation, chargement	✅ Terminée
Phase 3	Logs, orchestration et reprise sur incident	✅ Terminée
Phase 3	Planification automatique mensuelle (cron)	✅ Terminée
Phase 4	Contrôle qualité — 21 checks automatiques	✅ Terminée
Bonus	Tables CA analytiques (fact_ca_semaine + fact_ca_annuel)	✅ Terminée
Bonus	Table jointe fact_joint (7 980 correspondances)	✅ Terminée
Bonus	Dictionnaire de données complet	✅ Terminé
Bonus	Schéma logique documenté	✅ Terminé
Phase BI	Power BI / Tableau — tableaux de bord	🔜 À venir

8. Notes Techniques & Décisions d'Architecture

8.1 Indépendance des IDs client entre sources

Les IDs de dim_client sont construits par fusion des deux sources dans transform.py. Cependant les libellés clients peuvent différer légèrement entre les fichiers transfert et excursion, entraînant des IDs distincts. En conséquence, fact_ca_semaine calcule un ca_excursion à 0 pour les clients purement transfert et inversement — ce comportement est documenté et attendu.

8.2 Formats de dates hétérogènes

Colonne	Format brut	Conversion SQL
dim_date_transfert.[Date]	'2024 9 12' (AAAA M JJ)	REPLACE(' ','-') + TRY_CONVERT(DATE,.,23)
dim_date_excursion.Date_Excursion	'28/05/2025' (JJ/MM/AAAA)	TRY_CONVERT(DATE, ., 103)
dim_date_excursion.Date_Arrivee	'25/05/2025' (JJ/MM/AAAA)	TRY_CONVERT(DATE, ., 103)

TRY_CONVERT est utilisé partout à la place de CAST pour absorber les valeurs malformées sans lever d'erreur (Msg 241).